Ứng dụng kỹ thuật Data Mining và các mô hình học máy, học sâu, SLM trong bài toán tóm tắt văn bản tiếng Việt

Phan Văn Hoàng, Trần Lâm Doanh, Trần Thị Mỹ Tuyền và Nguyễn Thị Các Các
Khoa Công nghệ thông tin
Trường Đại học Nông Lâm TP. Hồ Chí Minh
Thành phố Hồ Chí Minh, Việt Nam
Email: {22130088, 22130041, 22130317, 22130028}@st.hcmuaf.edu.vn

***Tóm tắt nội dung*—Trong thời đại kỷ nguyên số việc tóm tắt văn bản đang là một trong những bài toán cơ bản, thách thức nhất đối với xử lý ngôn ngữ tự nhiên đặc biệt đối với cộng đồng ngôn ngữ tiếng Việt. Nghiên cứu này thực hiện so sánh hiệu suất giữa các kỹ thuật tóm tắt từ cổ điển đến hiện tại nhất: TextRank - LSTM - ViT5 - Phi-3-mini. Thực nghiệm thực hiện trên bộ dataset tin tức được thu thập từ Báo Lao Động [1], sau đó áp dụng các kỹ thuật tiền xử lý dữ liệu[1] thu được bộ dataset sạch gồm 275,650 bài báo, tất cả đều được đánh giá trên metric chuẩn ROUGE score và BERTscore. Kết quả cho thấy Phi-3-mini đã fine tune với QLoRA đạt điểm BERTScore F1 cao nhất (0.752), vượt qua tất cả các mô hình khác về chất lượng ngữ nghĩa, mặc dù ROUGE-1 (0.494) thấp hơn so với ViT5 đã fine tune (0,571). Điều này cho thấy model ViT5 đã fine tune đạt được độ khớp từ vựng cao nhất tuy nhiên nếu xét về mặt ngữ nghĩa thì Phi-3-mini đã fine tune tốt hơn cả. Mô hình đạt được tốc độ suy luận dưới 10 giây cho mỗi mẫu và không yêu cầu cấu hình quá cao cho thấy khả năng triển khai trên hệ thống máy chủ có tài nguyên hạn chế. Nghiên cứu này cung cấp một benchmark toàn diện cho tóm tắt tiếng Việt và chứng minh các mô hình nhỏ được tinh chỉnh thích hợp có thể đạt hiệu suất cạnh tranh với các mô hình lớn hơn trong ngôn ngữ đặc thù như tiếng Việt.**

***Index Terms*—Tóm tắt văn bản, ViT5, Phi-3-mini, TextRank, LSTM, LoRa, QLoRA, tiếng Việt, fine-tuning hiệu quả, ROUGE Score, BERT Score.**

1. Giới thiệu

Tóm tắt văn bản là một đề tài thảo luận sôi động trong những năm gần đây nhờ vai trò trung tâm trong các hệ thống tin tức trực tuyến, các công cụ tìm kiếm, các nền tảng lưu trữ tri thức đặc biệt là trong nền kinh tế tri thức lượng thông tin mà con người tiếp nhận tăng một cách đột biến. Khi lượng thông tin tăng nhu cầu rút trích và tổng hợp nội dung quan trọng từ văn bản gốc một cách ngắn gọn nhưng vẫn giữ nguyên được ngữ nghĩa đang trở nên cấp thiết hơn bao giờ hết.

Tuy nhiên phần lớn các nghiên cứu về tóm tắt văn bản hiện nay đa phần tập trung vào tiếng Anh và các ngôn ngữ phổ biến khác. Trong khi đó tiếng Việt với đặc trưng phức tạp về mặt ngôn ngữ giàu ngữ cảnh từ vựng, một từ có thể sẽ có nhiều nghĩa khác nhau phụ thuộc vào ngữ cảnh tạo nên từ các từ xung quanh. Điều này vô hình đã tạo ra khó khăn trong việc tóm tắt phải chọn đúng từ ngữ trong văn bản tóm tắt khi cấu trúc cũ bị thay đổi. Cùng với đó vẫn còn thiếu nhiều nghiên cứu đánh giá đồng thời các phương pháp tóm tắt từ cổ điển đến hiện đại trên một bộ dữ liệu đủ lớn và thống nhất.

Với xu hướng phát triển mạnh mẽ của các mô hình Transformer, LLM như BERT, T5, GPT đã mở ra nhiều hướng tiếp cận mới mẻ cho bài toán tóm tắt văn bản. Đối với tiếng Việt mô hình ViT5 nổi lên là một mô hình text-to-text được tiền huấn luyện trên dữ liệu tiếng Việt với quy mô lớn đã cho thấy hiệu quả vượt trội trong nhiều tác vụ sinh ngôn ngữ. Tuy nhiên việc fine-tuning các mô hình này tương đối cần nhiều tài nguyên trong tính toán gây khó khăn trong việc thử nghiệm và áp dụng.

Gần đây các kỹ thuật fine-tuning có chọn lọc giúp giảm tham số phải tính toán như LoRa, QLoRa đang nổi lên nhanh chóng. Chứng minh khả năng tinh chỉnh các mô hình với chi phí và thời gian thấp hơn mà vẫn giữ được hiện năng cao so với việc tinh chỉnh toàn bộ. Đồng thời sự xuất hiện của các mô hình ngôn ngữ nhỏ - Small Language Model (SLM) như Phi-3-mini đã đặt ra một câu hỏi quan trọng: liệu với các mô hình ngôn ngữ nhỏ khi tinh chỉnh đúng cách có cạnh tranh với các mô hình ngôn ngữ lớn (LLM) trong các tác vụ NLP cho tiếng Việt hay không.

Xuất phát từ những quan sát trên, nghiên cứu này tập trung phân tích một cách hệ thống các phương pháp tóm tắt với văn bản tiếng Việt từ các cổ điển tới hiện đại. Cụ thể nghiên cứu trả lời ba câu hỏi chính. Thứ nhất, sự khác biệt về chất lượng tóm tắt giữa các phương pháp cổ điển như TextRank, LSTM và các mô hình Transformer hiện đại như ViT5, Phi-3-mini trên cùng một bộ dữ liệu tin tức tiếng Việt? Thứ hai, các kỹ thuật fine-tuning như LoRa, QLoRa có thật sự giảm được chi phí tính toán mà vẫn giữ hiệu năng hay không? Thứ ba, các mô hình ngôn ngữ nhỏ (SLM) như Phi-3-mini được tinh chỉnh phù hợp có thể cạnh tranh được với mô hình encoder-decoder như ViT5 và các mô hình ngôn ngữ cùng tham số trong bài toán tóm tắt tiếng Việt hay không?

2. Các công trình liên quan

Các kỹ thuật tóm tắt được chia làm 2 nhóm chính là tóm tắt trích xuất (extraction) và tóm lược (abstraction). Tóm tắt

[1]https://www.kaggle.com/code/hoangper007/preprocess-news-dataset

trích xuất là rút trích các câu trực tiếp từ văn bản. Những câu này được tính toán lựa chọn sao cho chứa đựng nội dung tiêu biểu của văn bản. Ngược lại tóm tắt tóm lược là kỹ thuật hiểu tài liệu và sản sinh ra những câu văn hoàn toàn mới nhưng vẫn đảm bảo được nội dung của văn bản ban đầu.

Các nghiên cứu đầu tiên về tóm tắt văn bản chủ yếu tập trung vào phương pháp trích xuất dựa trên sắp xếp thứ hạng quan trọng và hệ thống đồ thị. Ví dụ Rada Mihalcea [4] đã đề xuất thuật toán graph-based unsupervised nổi tiếng lấy cảm hứng từ PageRank của Google. Đây là đề xuất kinh điển đặt nền móng cho sự ra đời của TextRank hiện đại sau này. Gần đây, năm 2018 Nguyen Minh Tien và những cộng sự [5] đã so sánh hiệu quả của nhiều thuật toán tóm tắt trích xuất trên tập dữ liệu tiếng Việt, bao gồm các phương pháp không giám sát như LexRank, LSA, KL-divergence cũng như các mô hình giám sát dựa trên học máy (SVM, AdaBoost, RankSVM) và mạng nơ-ron sâu (CNN, LSTM). Những đánh giá này cho thấy chưa có phương pháp nào vượt trội hơn mọi mặt, đồng thời cũng nêu ra tầm quan trọng của việc hiểu ngữ cảnh tổng quan của văn bản trước khi tóm tắt.

Những giới hạn của các mô hình truyền thống thúc đẩy nghiên cứu về mạng nơ-ron sâu. LSTM với mô hình sequence-to-sequence sử dụng cơ chế encoder–decoder nén thông tin từ văn bản đầu vào thành một vector ngữ cảnh có độ dài cố định sau đó sinh ra tóm tắt dựa trên vector ngữ cảnh dựa trên cơ chế teacher forcing. LSTM đã bước đầu hiểu được ngữ cảnh của văn bản. Tuy nhiên Bahdanau và cộng sự [6] đã chỉ ra rằng việc nén tất cả thông tin vào trong một vector cố định làm mất nội dung quan trọng. Để giải quyết vấn đề này, cơ chế Attention [7] được đề xuất và chứng minh được hiệu quả đáng kể, đặc biệt cho các tác vụ dịch máy và tóm tắt văn bản.

Transformer tiếp tục hoàn thiện với cơ chế self-attention hoàn chỉnh, thúc đẩy sự ra đời của các mô hình như BERT, T5 [8]. Trên cơ sở đó, Quốc và những cộng sự [9] đã áp dụng BERT cho bài toán tóm tắt trích xuất đa văn bản tiếng Việt. Họ tiến hành so sánh giữa các phiên bản BERT đơn ngôn ngữ và đa ngôn ngữ, sử dụng embedding từ BERT làm đặc trưng đầu vào cho bài toán tóm tắt. Kết quả thử nghiệm cho thấy các mô hình viBERT4News cho hiệu suất tốt hơn hẳn so với các mô hình đa ngôn ngữ và các phương pháp tóm tắt truyền thống trước đó.

Gần đây, xu hướng chuyển mạnh sang sử dụng các mô hình text-to-text và các mô hình ngôn ngữ lớn (LLM). ViT5 [10] là một mô hình Transformer encoder–decoder được tiền huấn luyện quy mô lớn cho tiếng Việt, đã cho thấy hiệu quả vượt trội trong nhiều tác vụ sinh ngôn ngữ, bao gồm tóm tắt trừu tượng. Song song đó, các mô hình ngôn ngữ nhỏ nhưng hiệu quả như Phi-3 [11], [12] cho thấy tiềm năng lớn khi được fine-tune cho các miền chuyên biệt, đặc biệt khi kết hợp với các kỹ thuật tối ưu tham số như LoRA và QLoRA, giúp giảm đáng kể chi phí huấn luyện mà vẫn duy trì hiệu năng. Nhờ các kỹ thuật tối ưu này, nhiều nghiên cứu về fine-tuning tiết kiệm VRAM và tăng tốc độ huấn luyện đã được công bố như Jun Wang [13], Imran Mansha [14], Swati Rallapalli [15].

Tổng quan các công trình có nêu trên cho thấy sự tiến hóa và kế thừa liên tục của các phương pháp tóm tắt văn bản. Tuy nhiên, nhìn chung chưa có nghiên cứu nào so sánh toàn bộ các phương pháp trên cùng một tập dữ liệu thống nhất, mà phần lớn các nghiên cứu chỉ đánh giá riêng lẻ từng hướng tiếp cận. Bên cạnh đó, các mô hình ngôn ngữ nhỏ như Phi-3 vẫn chưa được đánh giá đầy đủ cho bài toán tóm tắt, trong khi dữ liệu huấn luyện và đánh giá chủ yếu vẫn tập trung vào tiếng Anh. Những khoảng trống này mở ra hướng nghiên cứu xây dựng một hệ thống tóm tắt văn bản tiếng Việt hiệu quả, tiết kiệm tài nguyên và phù hợp với điều kiện triển khai thực tế.

3. Phương pháp

A. Bộ dữ liệu và tiền xử lý

Bộ dữ liệu gốc bao gồm 313,320 bài báo được thu thập từ Báo Lao Động trong giai đoạn từ năm 2014 đến năm 2022. Mỗi bản ghi có cấu trúc gồm các cột: *Title* (tiêu đề), *Contents* (nội dung bài báo), *Summary* (tóm tắt), *Category* (thể loại), *Author*, *Date*, *Tags* và *URL*. Tuy nhiên, dữ liệu thô này tồn tại nhiều vấn đề cần được xử lý trước khi đưa vào huấn luyện mô hình.

Kết quả kiểm tra ban đầu cho thấy có 180 bài báo bị thiếu *Summary*, 5,557 bài báo thiếu *Contents*, và tồn tại 23,032 bài báo trùng lặp hoàn toàn. Thêm vào đó, có 5 bài báo có trường *Title* giống hệt với *Summary*, không phản ánh nội dung tóm tắt thực sự. Bên cạnh đó, hơn 4,9% khoảng 15,374 bài báo) có độ dài *Contents* vượt quá 1,200 từ hoặc ngắn hơn 50 từ, vượt quá các giới hạn mà các mô hình có thể xử lý hiệu quả.

Để giải quyết vấn đề này, chúng tôi thiết kế một quy trình tiền xử lý dữ liệu gồm nhiều giai đoạn. Đầu tiên tập trung vào làm sạch HTML và chuẩn hóa text. Cụ thể, chúng tôi dùng BeautifulSoup để loại bỏ HTMLs, URLs, HASHTAG và `unicodedata.normalize()` với chuẩn NFC để chuẩn hóa các ký tự tiếng Việt có dấu.

Giai đoạn hai chúng tôi xóa các dòng dữ liệu trùng lặp hoàn toàn. Sau đó, xóa các bài báo có *Contents* vì *Contents* là bộ phận chính phản ánh nội dung bài báo. Cuối cùng, bỏ các bài báo có *Title* trùng với *Summary* vì chúng không thật sự được tóm tắt mà chỉ copy lại từ tiêu đề.

Giai đoạn thứ ba xóa các bản ghi bị thiếu dữ liệu và xử lý các bản ghi quá ngưỡng ở giai đoạn này. Việc xử lý ở giai đoạn này sẽ giúp các model học hiệu quả hơn, không nhận vào một context quá dài hoặc quá ngắn trong việc học.

Giai đoạn bốn, chúng tôi chia bộ dataset thành ba tập theo tỷ lệ 80/10/10 , các bài báo được chia theo cột *Category* nhằm đảm bảo thể loại bài báo ở mỗi tập là đồng đều. Việc chia theo phân bố Category nhằm đảm bảo mỗi tập con phản ánh đầy đủ đa dạng chủ đề, tránh hiện tượng mô hình hoạt động tốt trên một số lĩnh vực nhưng suy giảm hiệu năng trên các lĩnh vực khác.

Sau khi xử lý xong dataset còn lại 275,650 bài báo sẵn sàng đưa vào các phương pháp để tiến hành huấn luyện. Riêng đối với fine tune Phi-3-mini chúng tôi đã format thành dạng *instruction-following* để phù hợp với model [2].

[2]https://www.kaggle.com/code/hoangper007/preprocess-news-dataset

B. Các kỹ thuật fine-tuning

1) LoRA và QLoRA: Trong nghiên cứu này, LoRA và QLoRA được sử dụng nhằm đánh giá khả năng fine-tuning hiệu quả về tài nguyên cho các mô hình tóm tắt tiếng Việt, đặc biệt trong bối cảnh triển khai thực tế với GPU tầm trung, tài nguyên tính toán có giới hạn.

LoRa là một phương pháp fine tune tiết kiệm tham số. Thay vì cập nhật tất cả trọng số, LoRA thêm vào các ma trận nhân có thứ hạng thấp (low-rank matrices) có thể huấn luyện trong các lớp transformer. Cải tiến lớn của phương pháp là model sau khi fine tune có thể biểu diễn một cách hiệu quả cách sử dụng low-rank matrices từ đó làm giảm tổng các tham số cần phải trên lên đến 10000 lần (với fine tune model GPT-3 175B) và giảm 3 lần lượng VRAM yêu cầu.

$$\Delta W \approx A \times B^T \tag{1}$$

Trong đó $A \in \mathbb{R}^{d \times r}$: Ma trận A, $B \in \mathbb{R}^{k \times r}$: Ma trận B với r: Rank (thường 8–16). Chỉ A và B được huấn luyện; W gốc được đóng băng.

Nhờ đó, số lượng tham số cần huấn luyện giảm mạnh so với fine-tuning toàn bộ mô hình, đồng thời giảm đáng kể nhu cầu bộ nhớ và chi phí tính toán mà vẫn duy trì hiệu năng cạnh tranh.

QLoRA kết hợp lượng tử hóa 4-bit với LoRA để cho phép tinh chỉnh các mô hình rất lớn trên GPU có bộ nhớ hạn chế. Cụ thể, QLoRA sử dụng định dạng *NormalFloat 4-bit (NF4)* để lưu trữ trọng số đã đóng băng, đồng thời chỉ huấn luyện các LoRA adapters ở độ chính xác cao hơn. Ngoài ra, QLoRA áp dụng *Double Quantization* để giảm thêm footprint bộ nhớ và *Paged Optimizers* để quản lý bộ nhớ hiệu quả trong quá trình huấn luyện. Nhờ các kỹ thuật này, QLoRA cho phép fine-tuning các mô hình ngôn ngữ quy mô hàng chục tỷ tham số trên GPU có bộ nhớ hạn chế mà vẫn giữ được hiệu năng gần tương đương với fine-tuning ở độ chính xác cao.

Việc sử dụng LoRA và QLoRA trong nghiên cứu này cho phép đánh giá một cách hệ thống sự đánh đổi giữa hiệu năng, chi phí tài nguyên và khả năng triển khai thực tế, đặc biệt đối với các mô hình tóm tắt tiếng Việt có quy mô từ trung bình đến lớn.

C. Mô hình và thiết lập

1) ***TextRank****:* là phương pháp tóm tắt trích xuất dựa trên lý thuyết đồ thị. Trong đó, mỗi câu được coi là một đỉnh, còn các cạnh biểu thị mức độ tương đồng giữa các câu. Quy trình xử lý bao gồm các bước sau: (1) tách văn bản thành câu bằng `sent_tokenize` và tách từ bằng `word_tokenize`; (2) vector hóa các câu bằng TF–IDF; (3) xây dựng ma trận tương đồng bằng Cosine Similarity; (4) chuyển ma trận tương đồng thành đồ thị vô hướng; (5) áp dụng thuật toán PageRank để tính điểm cho mỗi câu; (6) trích xuất top-N câu có điểm số cao nhất và sắp xếp lại theo thứ tự xuất hiện ban đầu trong văn bản.

Thuật toán PageRank được cấu hình với các tham số: hệ số tắt dần $\alpha = 0{,}85$, số vòng lặp tối đa $\texttt{max_iter} = 200$, ngưỡng sai số $\texttt{tol} = 10^{-6}$ và số câu trích xuất cố định $\texttt{top_n} = 3$ nhằm tương ứng với độ dài trung bình của bản tóm tắt trong bộ dữ liệu.

2) ***LSTM****:* Mô hình LSTM là một bước chuyển tiếp giữa các phương pháp cổ điển và hiện đại, được xây dựng theo kiến trúc encoder–decoder kết hợp với cơ chế attention nhằm tăng khả năng hiểu ngữ cảnh của mô hình. Cụ thể, lớp Encoder trong nghiên cứu này sử dụng Bi-directional LSTM để đọc văn bản gốc theo cả chiều xuôi và chiều ngược, sau đó mã hóa văn bản đầu vào thành các vector trạng thái ẩn (*hidden states*). Các vector này chứa đựng thông tin ngữ cảnh của văn bản đầu vào.

Decoder sinh từng từ của bản tóm tắt dựa trên trạng thái ẩn trước đó kết hợp với context vector thu được từ cơ chế Attention. Cơ chế Attention cho phép Decoder tập trung vào các phần quan trọng của văn bản gốc tại mỗi bước sinh, giúp giảm gánh nặng tính toán và tránh việc nén toàn bộ thông tin vào một vector cố định duy nhất.

Trong nghiên cứu này, dữ liệu được token hóa ở mức từ. Từ điển túi từ được xây dựng gồm 30,000 từ phổ biến nhất, kèm theo các token đặc biệt như `[START]`, `[STOP]`, `[PAD]` và `[UNK]`. Các token này đóng vai trò quan trọng trong việc đảm bảo tính ổn định của quá trình huấn luyện, là đặc trưng không thể thiếu của các mô hình seq2seq truyền thống. Độ dài tối đa của văn bản và bản tóm tắt lần lượt là 500 và 100 token.

Trong quá trình huấn luyện, kỹ thuật Teacher Forcing được sử dụng, trong đó từ thực tế trong bản tóm tắt mục tiêu được đưa làm đầu vào cho bước tiếp theo thay vì từ do mô hình tự dự đoán. Cơ chế này giúp mô hình hội tụ nhanh hơn và cải thiện độ chính xác. Hàm mất mát được sử dụng là Cross-Entropy Loss cùng với optimizer Adam (`learning_rate` = 0,001, `batch_size` = 8) . Đồng thời, Beam Search với $K = 4$ được áp dụng để theo dõi bốn chuỗi có xác suất tổng thể cao nhất cùng lúc. So với Greedy Search, Beam Search giúp bản tóm tắt mạch lạc hơn và tránh việc lựa chọn những từ tối ưu cục bộ tại từng bước.

3) ***Fine-tune ViT5****:* ViT5 là mô hình Transformer encoder–decoder được thiết kế theo kiến trúc T5 của Google, gồm hai thành phần chính: Encoder tiếp nhận thông tin đầu vào và Decoder sinh văn bản đầu ra. ViT5 kế thừa đầy đủ cơ chế multi-head self-attention và mạng feed-forward của kiến trúc gốc. Ngoài self-attention, các lớp Decoder còn tích hợp cơ chế cross-attention nhằm tối ưu khả năng khai thác thông tin từ biểu diễn đầu vào đã được mã hóa.

ViT5 được tiền huấn luyện từ đầu cho tiếng Việt với bộ dữ liệu lớn khoảng 138GB trích từ CC100, giúp mô hình học được biểu diễn ngôn ngữ tiếng Việt hiệu quả. Trong nghiên cứu này, chúng tôi sử dụng ViT5-base gồm 12 encoder–decoder layer, 12 multi-head attention, kích thước embedding là 768 và kích thước tầng feed-forward là 3072. Tổng số tham số của mô hình ước tính khoảng 310 triệu.

Mô hình được fine-tune bằng kỹ thuật LoRA, trong đó trọng số gốc của ViT5 được giữ nguyên, chỉ cập nhật các tham số của adapter. Các adapter này được ghép với mô hình nền thông qua phép chiếu vào các thành phần query và value trong cơ chế attention. Cấu hình LoRA sử dụng trong nghiên cứu bao

gồm: rank $r = 16$, `lora_alpha` $= 32$, `dropout` $= 0{,}05$ và `target_modules` $= [\text{“}q'', \text{“}v'']$ theo khuyến nghị của kiến trúc.

Quá trình huấn luyện được thực hiện với `learning_rate` = 2×10^{-4}, `weight_decay` = 0,01, tổng `batch_size` = 16 và fine-tune trong 1 epoch. Việc fine-tune trong một epoch là do kích thước bộ dữ liệu tương đối lớn so với ViT5; huấn luyện quá nhiều epoch có thể khiến mô hình quên đi các tri thức tổng quát đã học trong giai đoạn tiền huấn luyện. Đồng thời, lựa chọn này cũng giúp tiết kiệm tài nguyên tính toán. Độ dài đầu vào và đầu ra của mô hình lần lượt là 512 và 128 token, đủ để tóm tắt các bài báo ngắn trong bộ dữ liệu.

*4) **Fine-tune Phi-3-mini**:* Phi-3-mini là một mô hình ngôn ngữ nhỏ theo kiến trúc decoder-only, được thiết kế tương tự LLaMA-2 nhưng có quy mô tham số nhỏ hơn. Mô hình gồm 32 lớp Transformer, mỗi lớp có 32 head multi-head self-attention, với kích thước mỗi head là 96 chiều, tương ứng với kích thước ẩn tổng cộng là 3072. Khối feed-forward network (MLP) có kích thước trung gian là 8192, sử dụng RMSNorm để chuẩn hóa và hàm kích hoạt SiLU. Tổng số tham số của Phi-3-mini khoảng 3,8 tỷ, cho phép mô hình đạt hiệu năng cao trong khi chi phí tính toán và tinh chỉnh giảm đáng kể so với các mô hình cỡ 7B như Phi-3-small hay LLaMA-7B.

Phi-3-mini sử dụng multi-head self-attention tiêu chuẩn trong kiến trúc decoder-only, trong đó mỗi attention thực hiện scaled dot-product attention trên toàn bộ query, key và value mà không sử dụng Grouped-Query Attention hay sliding window. Mô hình có độ dài ngữ cảnh mặc định là 4096 token và tận dụng Rotary Positional Embedding (RoPE) để mở rộng khả năng xử lý chuỗi dài. Phi-3-mini sử dụng tokenizer tương tự LLaMA-2 với khoảng 32 nghìn token và bổ sung các token đặc biệt phục vụ cho hội thoại và instruction-following, giúp mô hình dễ dàng tích hợp vào pipeline phát triển của LLaMA.

Trong nghiên cứu này, mô hình được fine-tune bằng kỹ thuật QLoRA, kết hợp lượng tử hóa 4-bit (NF4) cho trọng số gốc và LoRA adapter cho các tầng attention. Adapter được gắn vào mô hình nền thông qua các phép chiếu `q_proj`, `k_proj`, `v_proj`, `o_proj`, `gate_proj`, `up_proj` và `down_proj` theo khuyến nghị của kiến trúc Phi-3-mini. Cấu hình LoRA sử dụng gồm rank $r = 16$, `lora_alpha` $= 16$ và không sử dụng dropout. Việc đặt dropout bằng 0 phù hợp với xu hướng thiết kế của các mô hình Transformer decoder-only hiện đại, đồng thời kết hợp với kiến trúc pre-norm và RMSNorm giúp mô hình đạt khả năng regularization tự nhiên.

Quá trình huấn luyện được thực hiện với `adamw_torch_fused`, `learning_rate` $= 10^{-4}$, `weight_decay` = 0,01, `lr_scheduler_type` = “cosine” trong 1 epoch, tương tự cấu hình của ViT5. Cấu hình `bf16 = True` được sử dụng khi huấn luyện trên GPU A100 (Colab), nhằm tận dụng tối đa hiệu năng phần cứng trong khi vẫn đảm bảo chất lượng suy luận của mô hình gốc.

D. Metrics đánh giá

*1) **ROUGE score**:* ROUGE kiểm tra xem kết quả do mô hình tạo ra có khớp với kết quả thực tế do con người tạo ra hay không. Nói cách khác, nó đo lường mức độ khớp của các bản tóm tắt do máy tạo ra với các bản tóm tắt tham khảo do con người viết.

- **ROUGE-1:** đo lường mức độ trùng khớp của các từ đơn giữa bản tóm tắt sinh ra và bản tham chiếu.

$$\text{ROUGE-1} = \frac{\text{Số từ xuất hiện ở cả hai văn bản}}{\text{Tổng số từ trong bản tham chiếu}} \tag{2}$$

- **ROUGE-2:** đo lường mức độ trùng khớp của các cặp từ liên tiếp (bigram).

$$\text{ROUGE-2} = \frac{\text{Số cặp từ xuất hiện ở cả hai văn bản}}{\text{Tổng số cặp từ trong bản tham chiếu}} \tag{3}$$

- **ROUGE-L:** dựa trên độ dài của dãy con chung dài nhất (Longest Common Subsequence – LCS) giữa hai văn bản.

$$\text{ROUGE-L} = \frac{\text{Độ dài LCS}}{\text{Độ dài văn bản tham chiếu}} \tag{4}$$

*2) **BERT Score**:* Để đánh giá độ tương đồng ngữ nghĩa giữa văn bản do mô hình tạo ra và văn bản tham chiếu, BERTScore sử dụng embedding ngữ cảnh từ các mô hình như BERT.

- **Precision:** đo lường mức độ các từ trong câu ứng viên có tương ứng với câu tham chiếu (tức là câu ứng viên có chứa nhiều thông tin từ tham chiếu không).
- **Recall:** đo lường mức độ các từ trong câu tham chiếu có được bao phủ bởi câu ứng viên (tức là câu ứng viên có đầy đủ thông tin từ tham chiếu không).
- **F1-score:** trung bình điều hòa của Precision và Recall, cung cấp một điểm số tổng hợp.

4. THỰC NGHIỆM

A. Kết quả định lượng

Các kết quả định lượng được chúng tôi trình bày trong Bảng I và bảng II.

Bảng III báo cáo so sánh theo ngữ cảnh giữa các mô hình của chúng tôi và các mô hình ngôn ngữ lớn trước đây trên các benchmark tóm tắt. Mặc dù các tập dữ liệu và ngôn ngữ khác nhau, kết quả cho thấy rằng Phi-3-mini được tinh chỉnh của chúng tôi đạt được các điểm ROUGE cạnh tranh trong khi sử dụng ít hơn đáng kể các tham số và tài nguyên tính toán thấp hơn so với LLaMA-2-7B.

B. Dự đoán định tính

Để hiểu rõ sự khác biệt giữa các phương pháp ngoài những con số chúng ta cùng phân tích một ví dụ tiêu biểu về một ví dụ thực tế.

Văn bản gốc: Vụ 2 phóng viên bị dọa giết, bắt giữ, trái phép: Tạm đình chỉ công tác trưởng công an xã. Sáng 11.3, hai phóng viên báo Khánh Hòa là Tạ Văn Long và Phạm Thế Anh đi xe máy từ Nha Trang đến xã Khánh Thành (huyện khánh Vĩnh), rồi vào rừng phòng hộ của xã này để điều tra về hoạt động tại khai thác quặng vonfram tại đây. Sau đó, họ bị một nhóm người bắt giữ trái phép, dọa giết và cướp nhiều tài sản. Đáng chú ý trong nhóm người tham gia dọa giết, bắt giữ trái phép hai phóng viên này có người bị cụt tay, đeo tay giả. Ông Nguyễn Thanh Bình - Trưởng Công an xã Khánh Thành

Bảng I
SO SÁNH ROUGE VÀ BERT GIỮA CÁC PHƯƠNG PHÁP

Phương pháp	R-1	R-2	R-L	BERT-P	BERT-R	BERT-F1
TextRank	0.451	0.230	0.288	0.683	0.749	0.714
LSTM	0.188	0.071	0.188	0.728	0.740	0.734
ViT5 (Base)	0.303	0.089	0.221	0.429	0.403	0.412
ViT5 (Fine-tuned)	0.571	0.295	0.387	0.587	0.540	0.560
Phi-3-mini (Base)	0.202	0.111	0.154	0.601	0.712	0.651
Phi-3-mini (Fine-tuned)	0.494	0.278	0.344	0.756	0.753	0.752

Bảng II
SO SÁNH THỜI GIAN HUẤN LUYỆN VÀ TỐC ĐỘ INFERENCE

Phương pháp	Thời gian train	Yêu cầu GPU	Tốc độ inference
TextRank	0	CPU	0.04369s
LSTM	01:13:58	T4	0.03862s
ViT5 (Base)	—	T4	4.4302s
ViT5 (Fine-tuned)	09:25:22	T4	0.7342s
Phi-3-mini (Base)	—	T4	48s
Phi-3-mini (Fine-tuned)	09:13:56	T4	10s

Bảng III
SO SÁNH GIỮA PHI-3-MINI VÀ CÁC MÔ HÌNH NGÔN NGỮ LỚN TRÊN CÁC BENCHMARK TÓM TẮT

Model	Dataset	Params	R-1	R-2	R-L	Setting
LLaMA2-7B	CNN/DailyMail	7B	0.376	0.146	0.241	Fine-tuned
LLaMA2-7B	arXiv	7B	0.497	0.325	0.340	Fine-tuned
Mistral-7B	CNN/DailyMail	7.3B	0.374	0.165	0.245	Fine-tuned
Phi-3-mini (ours)	Vietnamese News	3.8B	0.494	0.278	0.344	QLoRA

cũng bị cụt tay, đeo tay giả. Tỉnh ủy đã giao công an tỉnh điều tra, làm rõ vụ việc.

Tóm tắt tham chiếu: Ngày 12.4, UBND huyện Khánh Vĩnh (tỉnh Khánh Hòa) cho biết, đã tạm đình chỉ công tác đối với ông Nguyễn Thanh Bình - Trưởng Công an xã Khánh Thành để làm rõ, xử lý trách nhiệm vì đã có dấu hiệu vi phạm những việc cán bộ, công chức không được làm.

TextRank: Sáng 11.3, hai phóng viên báo Khánh Hòa là Tạ Văn Long và Phạm Thế Anh đi xe máy từ Nha Trang đến xã Khánh Thành (huyện khánh Vĩnh), rồi vào rừng phòng hộ của xã này để điều tra về hoạt động tại khai thác quặng vonfram tại đây. Sau đó, họ bị một nhóm người bắt giữ trái phép, dọa giết và cướp nhiều tài sản. Đáng chú ý trong nhóm người tham gia dọa giết, bắt giữ trái phép hai phóng viên này có người bị cụt tay, đeo tay giả.

LSTM: Hai phóng viên báo Khánh Hòa bị bắt giữ trái phép khi điều tra khai thác quặng, trưởng công an xã bị đình chỉ

ViT5: Hai phóng viên báo Khánh Hòa bị một nhóm người bắt giữ trái phép, dọa giết và cướp nhiều tài sản.

Phi-3-mini: Vụ việc 2 phóng viên báo Khánh Hòa bị dọa giết, bắt giữ trái phép. Trái phép khai thác quặng vonfram được tỉnh Khánh Hòa phát hiện, đã tạm đình chỉ công tác trưởng công an xã Khánh Thành.

Từ kết quả định tính cho thấy sự khác biệt giữa các mô hình không chỉ nằm ở kết quả chính xác mà còn ở cách chúng nhận thức, hiểu nội dung của văn bản và diễn giải lại theo nghĩa ban đầu. Cụ thể TextRank nhờ phương pháp trích xuất thông tin từ văn bản gốc nên không có hiện tượng bịa nội dung - hallucination tuy nhiên vì trích xuất cả câu nên bản tóm tắt của TextRank có nhiều phần dư thừa. Ở chiều ngược lại LSTM và ViT5 có khả năng trừu tượng hóa nội dung tốt hơn song kiến trúc còn cứng ngắn nên ít tổng hơn được quan hệ nguyên nhân kết quả. Đáng chú ý Phi-3-mini có cách tiếp cận khác biệt tuy không giữ lại những từ vựng khớp với văn bản đầu nhưng về mặt ngữ nghĩa đầy đủ quan hệ nguyên nhân kết quả của vụ việc.

C. Phát hiện

Từ kết quả thực nghiệm định lượng và định tính, nghiên cứu này rút ra một số phát hiện quan trọng về hiệu quả của các phương pháp tóm tắt văn bản tiếng Việt từ cổ điển đến hiện đại.

Thứ nhất, phương pháp tóm tắt văn bản trích xuất truyền thống như *TextRank* vẫn duy trì được hiệu quả ở mức tương đối khá với các chỉ số ROUGE-1 và ROUGE-L dao động trong khoảng từ 0,230 đến 0,451. Tuy nhiên, bản tóm tắt chứa nhiều phần dư thừa vì nó trích xuất các câu nguyên vẹn từ văn bản gốc. Phương pháp không thể tổng quát nội dung chính làm giảm độ chính xác về ngữ nghĩa. Ưu điểm của phương pháp này là không bị hallucination vì tất cả thông tin đều có nguồn từ bài báo gốc.

Thứ hai, mô hình LSTM với sự hỗ trợ của cơ chế attention cho thấy sự cải thiện đáng kể về mặt ngữ nghĩa so với cụ thể các chỉ số BERTscore-P tăng khoảng 5% so với TextRank.

Tuy nhiên ROUGEscore lại thấp cho thấy mô hình gặp hạn chế về đồ bao phủ từ ngữ so với văn bản gốc. Phản ánh điểm yếu của kiến *seq2seq* trong việc xử lý một ngôn ngữ có độ khó cao như tiếng Việt.

Thứ ba, ViT5 đã được fine tune đạt ROUGE score cao nhất trong các mô hình được đánh giá cho thấy khả năng khớp từ vựng xuất sắc với văn bản gốc. Điều này vốn là điểm mạnh của các mô hình dòng encoder-decoder *text-to-text*. Tuy nhiên BERT score của ViT5 nhìn chung không quá cao bằng một số mô hình khác cho thấy hạn chế của số lượng token có thể tạo ra của ViT5 là không đủ cho một kết quả tóm tắt dài và cũng đôi khi là thiếu mối liên hệ giữa các sự kiện. Cụ thể phân tích định tính đã chỉ ra ViT5 không nắm bắt được quan hệ nguyên nhân kết quả của sự việc trong bài báo.

Thứ tư, mô hình Phi-3-mini cho thấy một hành vi đáng chú ý khi mô hình bảo toàn tối đa ý nghĩa của văn bản gốc cụ thể Phi-3-mini fine-tuned đạt BERTScore F1 cao nhất (0,752). Quan trọng hơn, phân tích định tính cho thấy Phi-3-mini có khả năng hiểu và diễn giải lại mối quan hệ nhân quả của sự việc. Mặc dù ROUGE score thấp hơn ViT5 vì mô hình không copy từ vựng cứng ngắc mà biến đổi cấu trúc một cách linh hoạt để truyền tải ý nghĩa.

Cuối cùng, thông qua thực nghiệm fine tune các mô hình như Phi-3-mini, ViT5 đã chứng minh hiệu quả của phương pháp fine tuning như LoRa và QLoRa khi Phi-3-mini fine-tuned chỉ mất 09:13:56 để huấn luyện (tương đương ViT5) nhưng sử dụng 3,8 tỷ tham số (so với 310 triệu của ViT5). Đối với thời gian inference của Phi-3-mini cần cải tiến thêm nếu cần một mô hình có tốc độ inference nhanh thì ViT5 là một lựa chọn tốt hơn cả với tốc độ 0,73 giây cho một mẫu dữ liệu.

5. KẾT LUẬN

Nghiên cứu này đã thực hiện đánh giá một toàn diện đồng bộ các phương pháp cổ điển đến hiện đại TextRank, LSTM, fine tune ViT5 và Phi-3-mini trên một tập dữ liệu đủ lớn từ bài báo tiếng Việt, quy trình tiền xử lý và thiết lập thực nghiệm thống nhất trên cùng một metrics đánh giá.

Kết quả cho thấy không tồn tại một mô hình có các chỉ số áp đảo so với các mô hình khác. TextRank đạt ROUGE cao nhất nhưng tóm tắt có xu hướng dài và dư thừa do trích xuất nguyên vẹn các câu. ViT5 fine-tuned nắm bắt được khớp từ vựng tốt nhất và tốc độ inference nhanh nhất phù hợp cho nhu cầu tóm tắt nhanh khớp từ vựng so với văn bản gốc. Ngược lại, Phi-3-mini fine-tuned thể hiện sức mạnh trong việc bảo toàn ý nghĩa văn bản gốc và giữ lại cấu trúc suy nhân quả - thời gian của văn bản gốc phù hợp cho nhu cầu tóm tắt ngắn gọn mà vẫn giữ hầu hết nội dung. Sự khác biệt này phản ánh khái niệm tóm tắt tốt có thể được định nghĩa khác nhau tùy thuộc vào mục đích của người sử dụng.

Một đóng góp đáng chú ý của nghiên cứu là chứng minh các mô hình ngôn ngữ như Phi-3-mini khi được tinh chỉnh hợp lý bằng QLoRa hoàn toàn có thể cạnh tranh với các mô hình ngôn ngữ lớn hớn như LLaMA-2-7B hay Mistral-7B. Trong nghiên cứu của chúng tôi Phi-3-mini không chỉ đạt được BERT score cao mà thời gian fine tuning cũng rút gọn rất nhiều chỉ 9 tiếng xấp xỉ bằng thời gian fine-tuning của ViT5 trong khi Phi-3-mini là 3,8 tỷ tham số còn ViT5 là 310 triệu tham số. Kết quả này mang ý nghĩa thực tiễn lớn đối với các tổ chức có tài nguyên GPU hạn chế. Đồng thời phần cứng để triển khai mô hình cũng rất khả thi đối với máy chủ tầm thấp hiện nay phù hợp với các hệ thống tin tức trực tuyến hay hệ thống lưu trữ nhỏ. Ngoài ra quy trình xử lý dữ liệu và đánh giá các mô hình có thể đóng góp vai trò như một benchmark tham chiếu cho các nghiên cứu đối với văn bản tiếng Việt giúp rút ngắn khoảng cách tài nguyên nghiên cứu giữa văn bản tiếng Việt và văn bản nước ngoài.

Mặc dù đạt kết quả khả quan nhưng nghiên cứu còn một số hạn chế mở ra nhiều hướng nghiên cứu, phát triển tiềm năng. Cần thêm bộ đánh giá con người nhằm kiểm nghiệm kết quả của bộ đánh giá tự động tăng độ chính xác về ngữ nghĩa, bảo toàn thông tin, mạch lạc trong diễn đạt. Đồng thời làm rõ cải thiện các lỗi hallucination (tạo thông tin không có trong văn bản gốc) giúp hiểu rõ điểm yếu của các mô hình hiện đại. Mở rộng đánh giá trên nhiều nguồn dữ liệu khác nhau: tài liệu hành chính, pháp lý, y tế, giáo dục, bài báo khoa học, báo cáo tài chính, ... Kết các mô hình lại với nhau để tận dụng được sức mạnh và hạn chế các điểm yếu của từng mô hình. Với những cải tiến này, các hệ thống tóm tắt tiếng Việt sẽ tốt hơn trong việc đáp ứng nhu cầu thực tiễn của các ứng dụng tin tức, tìm kiếm thông tin và lưu trữ kiến thức trong kỷ nguyên số.

TÀI LIỆU

[1] HoangPhan. (2025). *process News Dataset*, Kaggle Datasets, 2023. Available: https://www.kaggle.com/datasets/phamtheds/news-dataset-vietnameses

[2] P. Pham et al., *Vietnamese News Dataset*, Kaggle Datasets, 2023. Available: https://www.kaggle.com/code/hoangper007/preprocess-news-dataset

[3] HoangPhan. (2025). *Code convert format* [Source code]. Colab. Available:https://colab.research.google.com/drive/1aiSgLMjVlt8WM3j0C-18Q1Bah4J00IMJ#scrollTo=aUtkpruWYHaK

[4] R. Mihalcea and P. Tarau, *TextRank: Bringing Order into Texts*, Proceedings of EMNLP, 2004. Available: https://aclanthology.org/P04-3020.pdf

[5] N. M. Tien, T. T. Nguyen, and H. T. Le, *Learning to Estimate the Importance of Sentences for Multi-Document Summarization*, Proceedings of the International Conference on Knowledge and Systems Engineering (KSE), 2018.

[6] D. Bahdanau, K. Cho, and Y. Bengio, *Neural Machine Translation by Jointly Learning to Align and Translate*, arXiv:1409.0473, 2014. Available: https://arxiv.org/pdf/1409.0473

[7] A. Vaswani et al., *Attention Is All You Need*, NeurIPS, 2017. Available: https://arxiv.org/abs/1706.03762

[8] C. Raffel et al., *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer*, arXiv:1910.10683, 2019. Available: https://arxiv.org/pdf/1910.10683

[9] P. Q. Quoc, N. T. H. Phuong, and T. M. Hieu, *Applying BERT for Vietnamese Multi-document Extractive Summarization*, Proceedings of the Asian Conference on Intelligent Information and Database Systems (ACIIDS), 2018.

[10] N. H. Pham et al., *ViT5: Pretrained Text-to-Text Transformer for Vietnamese*, arXiv:2205.06457, 2022. Available: https://arxiv.org/pdf/2205.06457

[11] Phi-3 Meets Law, 2024. Available: https://www.researchgate.net/publication/387996568

[12] Phi-3 Technical Report, arXiv:2404.14219, 2024. Available: https://arxiv.org/pdf/2404.14219

[13] J. Wang, arXiv:2510.25460, 2025.

[14] I. Mansha, arXiv:2510.05003, 2025.

[15] S. Rallapalli, arXiv:2503.10676, 2025.
[16] Mastering ROUGE Matrix: Your Guide to Large Language Model Evaluation for Summarization with Examples, DEV Community article, 2025. (trình bày tổng quan về các chỉ số ROUGE và cách tính toán trong bài toán tóm tắt văn bản).
[17] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, Yoav Artzi, "BERTScore: Evaluating Text Generation with BERT", *arXiv preprint*, arXiv:1904.09675, 2019. (đề xuất BERTScore như một metric đánh giá ngữ nghĩa cho các tác vụ sinh ngôn ngữ).

PHỤ LỤC A
DANH MỤC MÃ NGUỒN VÀ TÀI NGUYÊN TRỰC TUYẾN

Để đảm bảo tính minh bạch và khả năng tái lập của nghiên cứu, nhóm tác giả công khai toàn bộ mã nguồn, dữ liệu tiền xử lý và các checkpoint mô hình tại các địa chỉ dưới đây.

A. Mã nguồn Tiền xử lý và Chuyển đổi dữ liệu

- **Tiền xử lý dữ liệu thô:** https://www.kaggle.com/code/hoangper007/preprocess-news-dataset
- **Chuyển đổi định dạng Instruction:** https://colab.research.google.com/drive/1aiSgLMjVlt8WM3j0C-18Q1Bah4J00IMJ

B. Huấn luyện mô hình và Checkpoints

- **Mô hình ViT5 (Checkpoint):** https://huggingface.co/lamdoanh2468/vit5-fast
- **Mã nguồn Fine-tune ViT5:** https://www.kaggle.com/code/lamdoanh/vn-text-vit5-train-new-model/notebook
- **Mã nguồn Fine-tune Phi-3-mini:** https://colab.research.google.com/drive/1QpdCrY8c-rMsl9GF-fuNm4JY0yhxzYjB
- **Mã nguồn thực nghiệm LSTM :** https://colab.research.google.com/drive/1ccjnO58GJE91_61Lpi_fnpIZEnnakJEo
- **TextRank (TF-IDF & Cosine Similarity):** https://www.kaggle.com/code/cacaz1025/textrank-tf-idf-cosine-similarity

C. Đánh giá mô hình (Evaluation Metrics)

- **Đánh giá ViT5:** https://www.kaggle.com/code/doanhtrnlm/vn-text-vit5
- **Tính toán ROUGE và BERTScore:** https://colab.research.google.com/drive/17TECcJW-OW1G2jmDYwoQUKu8pKssQtp7